

# Statystyczna analiza sezonów 2019-2024 Formuły 1

January 21, 2025

## 1 O projekcie

Projekt koncentruje się na statystycznej analizie sezonów 2019-2024 Formuły 1, obejmując punkty zdobyte przez kierowców i zespoły, wydajność zespołów w wyścigach oraz wyniki rywalizacji na torze. Analiza uwzględnia dynamikę punktacji oraz zależności między pozycjami startowymi a wynikami końcowymi. Celem projektu jest zidentyfikowanie najważniejszych czynników wpływających na wyniki sezonu, a także dostarczenie wniosków opartych na danych, które pozwolą lepiej zrozumieć rywalizację w tej dyscyplinie.

### 1.1 Wykorzystywane biblioteki

## 2 Gromadzenie i czyszczenie danych

Do pozyskania danych wyścigowych wykorzystano Ergast API, które oferuje otwarty dostęp do szczegółowych informacji o Formule 1, takich jak wyniki wyścigów, pozycje startowe, zdobyte punkty, czy statystyki zespołów i kierowców. API umożliwia pobieranie danych w formacie JSON, co ułatwia ich obróbkę z użyciem Python'a.

W ramach projektu zgromadzono dane obejmujące sezony od 2019 do 2024 włącznie, które zostały przechowywane w bazie SQLite.

W jednej analizie użyłem biblioteki `fastfl` do analizy tempa wyścigowego. Dane zgromadzone w Ergast API nie uwzględniały pitstopów, samochodu bezpieczeństwa, flag itp., więc nie było prostego sposobu, żeby oczyścić dane o czasie okrążenia. Biblioteka `fastfl` pozwoliła mi wyizolować okrążenia "szybkie" (bez żadnych zakłóceń zewnętrznych) i je przeanalizować.

Należy pamiętać, że sezon 2020 został znacznie skrócony przez pandemię COVID, od sezonu 2022 znacznie zmieniła się zasady techniczne co do aerodynamiki i silnika bolidów, co spowodowało znaczne zmiany w osiągnięciach drużyn.

W analizie używam tylko nazw (i kolorów) zespołów z 2024 roku, nazwy (i kolory) drużyn z poprzednich lat zostały zmienione na te aktualne (np. Renault na Alpine).

Kierowcy, którzy w tym okresie zmienili drużynę, są przypisani do najaktualniejszej drużyny (np. Sebastian Vettel jest przypisany do drużyny Aston Martin, a w 2019-2020 był w Ferrari, 2021-2022 w Astonie Martinie, potem przeszedł na emeryturę).

Funkcja `ergast_retrieve` pobiera dane z Ergast API dla podanego endpointu.

**Łącze się z bazą danych:**

Tabele w bazie danych:

- constructors
- constructorStandings
- qualifyingResults
- raceResults
- drivers
- driverStandings

Następnie wprowadzam dane z API do bazy danych. (Część danych nie była bezpośrednio dostępna w API, więc musiałem je wprowadzić do bazy danych z ręki (kolumny `constructors(colorHex)` oraz `drivers(constructorId)`)

Dla `driverStandings` dodałem dane precyzujące, że na początku sezonu 2019 kierowcy nie mieli punktów.

Analogicznie dla `constructorsStandings`

Dla `raceResults` potrzebne było zmodyfikowanie przypadków, gdy kierowcy zaczynali z alei serwisowej, oznaczone przez API jako start z zerowej pozycji. Dla wszystkich tych przypadków pozycję startową = 20 (Start z alei serwisowej obiektywnie jest gorszy niż start z pozycji 20, ponieważ kierowcy mogą wyjechać dopiero po przejechaniu wszystkich kierowców za linie końca wyjazdu z alei serwisowej.).

Zbieram dane do tabeli `qualifyingResults` osobno, ponieważ grid z tabeli `raceResults` nie zawsze jest równoznaczny z pozycją kwalifikacji (kary, zmiany części itp.).

### 3 Analiza eksploracyjna danych

#### 3.1 Ogólne przedstawienie danych

Liczba wierszy w każdej tabeli:

Tabela 'constructors': 10 wierszy

Tabela 'constructorStandings': 1290 wierszy


Tabela 'qualifyingResults': 2556 wierszy

Tabela 'raceResults': 2559 wierszy

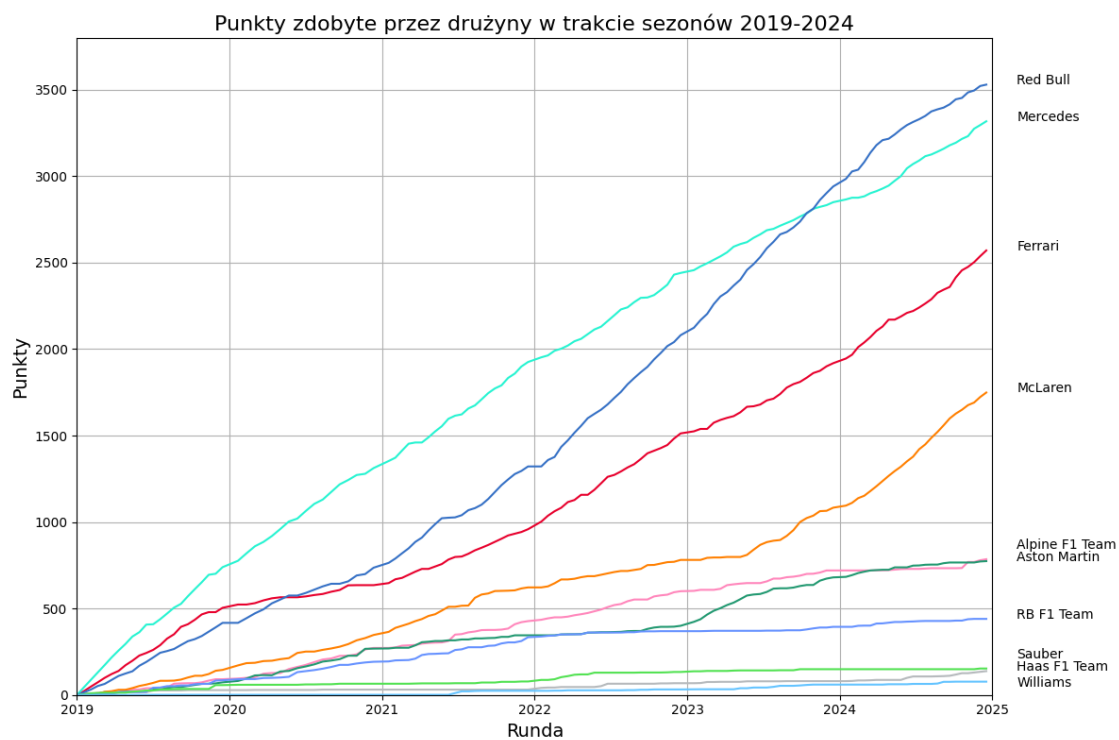
Tabela 'drivers': 36 wierszy

Tabela 'driverStandings': 2696 wierszy

Poniżej przedstawiłem wizualizację punktów zdobytych na przestrzeni ostatnich 6 lat przez 10 najlepszych kierowców w tym okresie.




Poniżej przedstawiłem wizualizację punktów zdobytych na przestrzeni ostatnich 6 lat przez 10 najlepszych kierowców w tym okresie.



## 3.2 Analiza eksploracyjna

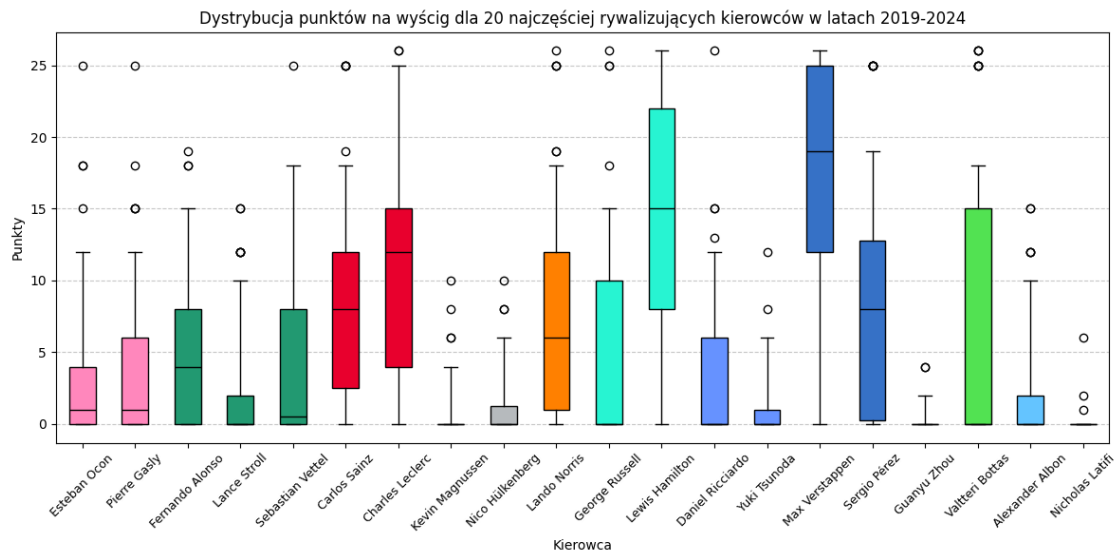
### Analiza rywalizacji Lewisa Hamiltona oraz Maxa Verstappena



Zliczenie wszystkich przypadków nie ukończenia wyścigu dla 20 najczęściej rywalizujących kierowców.

fault_type	car_fault	driver_fault	total_dnfs	average_driver_fault
name				
Alexander Albon	4	10	14	0.714286
Carlos Sainz	4	10	14	0.714286
Charles Leclerc	5	9	14	0.642857
Daniel Ricciardo	0	4	4	1.000000
Esteban Ocon	2	6	8	0.750000
Fernando Alonso	4	1	5	0.200000
George Russell	5	7	12	0.583333
Guanyu Zhou	2	3	5	0.600000
Kevin Magnussen	6	11	17	0.647059
Lance Stroll	4	12	16	0.750000
Lando Norris	2	5	7	0.714286
Lewis Hamilton	2	4	6	0.666667
Max Verstappen	6	6	12	0.500000
Nicholas Latifi	1	8	9	0.888889
Nico Hülkenberg	4	3	7	0.428571
Pierre Gasly	4	7	11	0.636364
Sebastian Vettel	2	6	8	0.750000
Sergio Pérez	4	9	13	0.692308
Valtteri Bottas	5	7	12	0.583333
Yuki Tsunoda	4	6	10	0.600000


Analiza wydajności kierowców w wyścigach pod względem punktów



Podsumowanie punktów dla kierowców:

	count	mean	std	min	25%	50%	75%	max
driverName								
Charles Leclerc	128.0	10.343750	7.214855	0.0	4.00	12.0	15.00	26.0
Lando Norris	128.0	7.421875	6.813152	0.0	1.00	6.0	12.00	26.0
Max Verstappen	128.0	17.519531	8.664663	0.0	12.00	19.0	25.00	26.0
Sergio Pérez	126.0	8.380952	7.314487	0.0	0.25	8.0	12.75	25.0


Analiza wydajności kierowców w kwalifikacjach



Podsumowanie kwalifikacji dla kierowców:

	count	mean	std	min	25%	50%	75%	max
driverName								
Charles Leclerc	128.0	5.179688	3.955328	1.0	2.0	4.0	7.00	19.0
Lando Norris	128.0	7.218750	4.044901	1.0	4.0	7.0	10.00	19.0
Max Verstappen	128.0	3.156250	3.239611	1.0	1.0	2.0	3.25	20.0
Sergio Pérez	126.0	8.420635	5.163492	1.0	4.0	8.0	12.00	20.0

## Analiza Grand Prix Meksyku 2024



Team	count	mean	std	min	25%	50%	\
Alpine	115.0	82.533922	0.907797	80.659	81.5690	82.7120	
Aston Martin	61.0	82.504295	0.746669	81.311	81.6840	82.7220	
Ferrari	124.0	81.158944	0.727162	78.336	80.6100	80.9720	
Haas F1 Team	119.0	82.040697	0.888920	80.637	81.3550	81.8320	
Kick Sauber	104.0	82.758327	0.900550	81.085	81.8320	83.1120	
McLaren	119.0	81.396134	1.144547	79.691	80.4190	80.8810	
Mercedes	125.0	81.712920	0.824893	80.371	81.0360	81.4360	
RB	55.0	82.516782	0.906808	79.502	81.6990	82.8150	
Red Bull Racing	114.0	81.924421	0.806680	79.209	81.2705	81.7120	
Williams	56.0	82.449821	1.012770	80.090	81.5345	82.8085	

Team	75%	max
Alpine	83.35450	83.812

Aston Martin	83.17300	83.681
Ferrari	81.77925	82.888
Haas F1 Team	82.93050	83.805
Kick Sauber	83.55725	83.806
McLaren	82.47400	83.793
Mercedes	82.46900	83.557
RB	83.23250	83.812
Red Bull Racing	82.39900	83.740
Williams	83.20000	83.787

### 3.3 Testy statystyczne

#### T-Test liczby punktów w wyścigach między zespołami McLaren i Mercedes

H (hipoteza zerowa): Średnia liczba punktów zespołu McLaren jest równa średniej liczbie punktów zespołu Mercedes.

H (hipoteza alternatywna): Średnie liczby punktów zespołów McLaren i Mercedes różnią się.

T-statystyka: -6.4344330156716

Wartość p: 6.44686432765855e-08

$p < 0.05 \Rightarrow$  Odrzucam  $H_0$ . Średnie liczby punktów zespołów McLaren i Mercedes różnią się.

$T\text{-statystyka} < 0 \Rightarrow$  Średnia liczba punktów zespołu McLaren jest niższa niż średnia liczba punktów zespołu Mercedes.

#### T-Test liczby punktów w wyścigach między kierowcami Red Bulla Maxem Verstappenem i Sergio Perezem

H (hipoteza zerowa): Średnia liczba punktów Sergio Pereza jest równa średniej liczbie punktów Maxa Verstappena.

H (hipoteza alternatywna): Średnie liczby punktów Sergio Pereza i Maxa Verstappena różnią się.

T-statystyka: 8.276264210798482

Wartość p: 2.913033642054163e-14

$p < 0.05 \Rightarrow$  Odrzucam  $H_0$ . Średnie liczby punktów Sergio Pereza i Maxa Verstappena różnią się.

$T\text{-statystyka} > 0 \Rightarrow$  Średnia liczba punktów Sergio Pereza jest niższa niż średnia liczba punktów Maxa Verstappena.

#### Test ANOVA punktów na wyścig między 4 najlepszymi zespołami.

Hipoteza zerowa (H): Średnie wyniki wszystkich zespołów są równe.

Hipoteza alternatywna (H): Przynajmniej jeden zespół ma inny średni wynik.


	round	constructorId	points
0	1	ferrari	133.0
1	1	mercedes	114.0
2	1	red_bull	138.0
3	2	ferrari	105.0
4	2	mercedes	112.0

Statystyka F: 9.076646323102544

Wartość p: 0.000316593906688837

Odrzucamy hipotezę zerową: Istnieją istotne różnice między zespołami.

### 3.4 Analiza regresyjna



$R^2$  dla regresji to: 0.31013856967514564

p-value dla regresji to: 3.421341055050447e-51

```
position
1      0.500000
2      0.179688
3      0.117188
4      0.054688
5      0.007812
6      0.007812
7      0.015625
8      0.007812
9      0.015625
15     0.007812
```



```
18    0.007812
19    0.039062
20    0.039062
Name: count, dtype: float64
```

```
position
1      0.236220
2      0.314961
3      0.165354
4      0.062992
5      0.023622
6      0.031496
7      0.023622
8      0.015748
9      0.015748
10     0.007874
11     0.023622
15     0.007874
16     0.015748
17     0.007874
18     0.015748
19     0.007874
20     0.023622
Name: count, dtype: float64
```

Przewidywana pozycja końcowa dla kierowcy zaczynającego z 30 pozycji to:  
27.16723727649809  
Przewidywana pozycja końcowa dla kierowcy zaczynającego z 38 pozycji to:  
34.01183388356424

## 4 Wnioski

### 4.1 Wpływ pozycji w kwalifikacjach

Analiza statystyczna potwierdziła, że pozycja startowa ma istotny wpływ na wynik kierowcy w wyścigu. Lepsze wyniki w kwalifikacjach znacząco zwiększają szansę na wysokie miejsce na mecie, co jest zgodne z charakterystyką Formuły 1, gdzie trudność w wyprzedzaniu oraz strategia wyścigowa silnie zależą od pozycji początkowej.

- Kierowcy startujący z pierwszego rzędu (pozycje 1–2) częściej osiągają miejsca na podium. (Aż 79,7% z 1 miejsca i 71,6% z miejsca 2)

### 4.2 Wpływ zespołu

Wyniki kierowców były w dużej mierze zależne od ich zespołów, co wskazuje na kluczową rolę technologii, strategii wyścigowej oraz wydajności samochodu/ Dominacja zespołów takich jak Mercedes i Red Bull była szczególnie widoczna w okresie 2019-2024, co potwierdzają zarówno liczba wygranych wyścigów, jak i miejsc na podium. Zmiany zespołów z lepszych na gorsze i na odwrót

bardzo odbijają się na wynikach kierowców: - Przejście Valtterego Bottasa z Mercedesa do Saubera w 2022 roku spowodowała spadek średniej liczby punktów na sezon z 258.3 do 19.6.

### **4.3 Indywidualna wydajność kierowców**

Poza pozycją startową i zespołem, indywidualna wydajność kierowców odegrała istotną rolę w osiągniętych wynikach. Widać to było po różnicach wyników między kierowcami tego samego zespołu: - Max Verstappen zdobywał średnio aż o 9.1 punktów więcej na wyścig niż jego kolega zespołowy Sergio Perez.

## **5 Podsumowanie**

Przeprowadzenie tej analizy danych umożliwiło mi pogłębienie wiedzy z zakresu statystyki i analizy danych, a także zachęciło do dalszego korzystania z języka Python i użytych bibliotek. Ich wszechstronność oraz intuicyjna obsługa sprawiają, że są doskonałym narzędziem do pracy z danymi.